

Machine Learning

Aufgabe 1. LDA

12 P.

- (a) Nennen Sie die grundlegende Verteilungsannahme, die der Gaußschen Diskriminanzanalyse zugrunde liegt und aufgrund welcher Kriterien Beobachtungen klassifiziert werden.
- (b) Nennen Sie die spezifischen Verteilungsannahmen und Modellparameter der folgenden Modelle:
- Quadratische Diskriminanzanalyse (QDA)
 - Lineare Diskriminanzanalyse (LDA)
 - Naive Bayes
- (c) Zeigen Sie, dass im Falle von nur zwei Klassen, die LDA-Entscheidungsregionen halbräume sind, d.h. dass Sie durch eine Gleichung der Form $\mathbf{w}^\top \mathbf{x} > c$ bzw. $\mathbf{w}^\top \mathbf{x} < c$ beschrieben werden können. Bestimmen Sie außerdem eine Formel für $\mathbf{w} \in \mathbb{R}^d$ und $c \in \mathbb{R}$ in Abhängigkeit der Parameter des LDA Modells.
- (d) Zeigen Sie, dass im Falle von nur zwei Klassen, die QDA-Entscheidungsgrenze die Lösung einer quadratischen Gleichung der Form $\mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c = 0$ ist. Hierbei ist $\mathbf{A} \in \mathbb{R}^{d \times d}$ eine Matrix, $\mathbf{b} \in \mathbb{R}^d$ ein Vektor und $c \in \mathbb{R}$ ein Skalar. Bestimmen Sie außerdem eine Formel für \mathbf{A} , \mathbf{b} und c in Abhängigkeit der Modellparameter.

Gegeben sind nun die folgenden Beobachtungen.

$$\begin{array}{c|cccc|cccc} x_1 & \sqrt{3} & -\sqrt{3} & \sqrt{5} & -\sqrt{5} & 2+\sqrt{5} & 2-\sqrt{5} & 2+\sqrt{3} & 2-\sqrt{3} \\ x_2 & \sqrt{3} & -\sqrt{3} & -\sqrt{5} & \sqrt{5} & 2+\sqrt{5} & 2-\sqrt{5} & 2-\sqrt{3} & 2+\sqrt{3} \\ y & 1 & 1 & 1 & 1 & 2 & 2 & 2 & 2 \end{array}$$

Fitten Sie ein QDA Modell an die Daten. Gehen Sie dabei folgendermaßen vor.

- (e) Fitten Sie ein QDA Modell an die Daten. Nutzen Sie dazu die aus der Vorlesung / dem Lehrbuch bekannten Formeln für die Maximum-Likelihood Parameter Schätzungen.
- (f) Skizzieren Sie die Verteilungen $p(x|y=c)$ in dem Sie mehrere Niveaumengen der entsprechenden Dichtefunktionen handschriftlich in ein Koordinatensystem einzeichnen. Achten Sie dabei besonders auf die Form der Niveaumengen.
- (g) Setzen Sie die Modellparameter in die Gleichung für die Entscheidungsgrenze aus Teilaufgabe (d) ein. Lösen Sie die Gleichung nach x_2 (also nach der zweiten Koordinate von \mathbf{x}).
- (h) Beschreiben Sie die Form der Entscheidungsgrenze und zeichnen Sie sie in ihre Skizze aus Teilaufgabe (f) ein.