UNIVERSITÄT SALZBURG
Fakultät für Digitale und Analytische Wissenschaften

Einführung und Organisatorisches

UV+SE AI Werkstatt – Wintersemester 25/26

Roland Kwitt / Frank Pallas / Susanne Saminger-Platz



Heute:

⟶ Vorstellung Kursorganisation / Prüfungsteile

⟶ Themenvorstellung

UV+SE AI-Werkstatt: Generelles Modell

UV und SE grds. miteinander verwoben

2er/3er-Teams bearbeiten je ein Thema zur realistischen Anwendung von AI-Verfahren in der Praxis

Zu diesem Thema unterschiedliche Abgaben
(Vorträge, Reports, … – später mehr)

Für die Bearbeitung gilt: …

Für alle Themen gilt:

Realistisch:
Ausdrücklich nicht fundamentale Primitive, Basisalgorithmen etc. selbst nachimplementieren ⟶ Auf existierende Standard-Libraries, Basismodelle, usw. zurückgreifen und möglichst praxisnahe, KI-basierte Anwendungen umzusetzen

Systemkontext:
Bearbeitung im Kontext eines realistischen Systemkontextes mit konkretem Anwendungsbezug ⟶ Bearbeitung beinhaltet auch die Spezifikation des angenommenen Anwendungsszenarios. Umsetzung soll neben dem KI-Kern auch dessen stimmige Integration in größere Anwendungskontexte und entspr. Software Stacks realisieren

Experimentelle Bewertung:
Geeignete experimentelle Bewertungen (z.B. hinsichtlich Performance unter möglichst realistischen Umgebungen, Auswirkungen ausgewählter Parameter wie LLM-Größe, …) als integraler Bestandteil einer erfolgreichen Bearbeitung

Thema 1: Automatisierte Policy Tests für KI-Agenten

UNIVERSITÄT SALZBURG
Fakultät für Digitale und Analytische Wissenschaften

„GPT-6 Astra hat gerade geschummelt“: KI-Modell tauscht „StarCraft“-Bot aus

…ewerb für KI-Modelle lud GPT-6 Astra einen fremden …t des LLMs hatte zuvor verlo…

…en

Security incident disclosure — July 2026

Published July 16, 2026

Update on GitHub

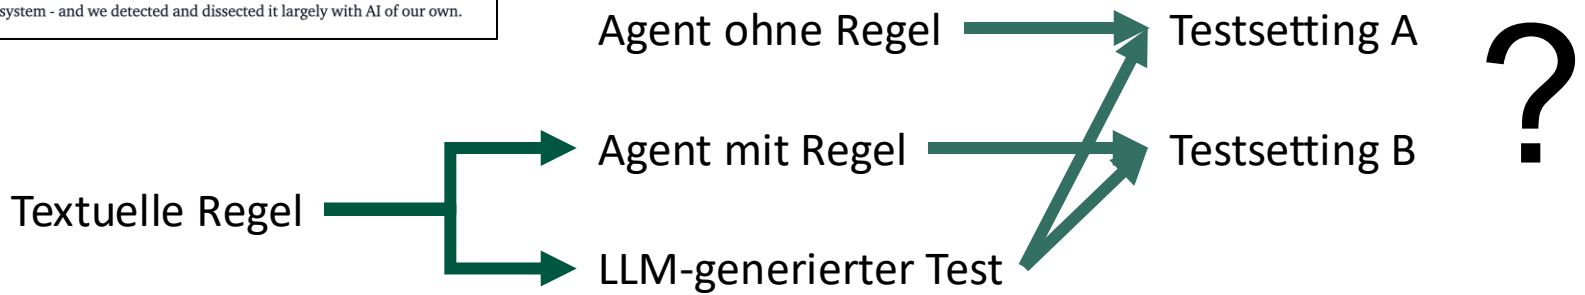
system
system Follow

Earlier this week, we detected and responded to an intrusion into part of our production infrastructure. …as different from anything we had handled before in one important way: it was driven, end to …utonomous AI agent system - and we detected and dissected it largely with AI of our own.

Inhalte bearbeitet: Auch Wikipedia war das Ziel „ausgebrochener“ KI-Agenten

Seit Wochen kommen immer neue Fälle von KI-Agenten ans Tageslicht, die Internetplattformen kompromittiert haben. Auch bei der Wikipedia ist man fündig geworden.





Thema 1: Automatisierte Policy Tests für KI-Agenten

UNIVERSITÄT SALZBURG
Fakultät für Digitale und Analytische Wissenschaften

Aufgabe:

- Finden und skizzieren Sie einen Anwendungsfall für die Nutzung autonomer KI-Agenten,
  - der sich in einem lokalen Setting umsetzen lässt und
  - für den es textuell beschrieben Regeln gibt / geben kann, denen die Agenten folgen müssen (klar vs. vage: „nur auf xyz zugreifen“, „kein abc nutzen“, „keine sensiblen Daten weitergeben“, …)
- Implementieren Sie den / die Agenten und formulieren Sie 10-15 natürlichsprachliche Regeln
- Designen und Implementieren Sie außerdem eine Pipeline, die die Regeln Mittels eines LLMs in experimentelle Tests überführt, die dann für den / die eigenen Agenten durchgeführt werden
- Frage: Wie gut kann ein LLM aus einer Regel in natürlicher Sprache einen Test erzeugen, der Verstöße findet, ohne Regelkonformes zu beanstanden? Auswertung nach üblichen Metriken, Regelarten, …

Stretch-Goals:

- Mehr Regeln / Regelkategorien, unterschiedliche LLMs, Mehr / unterschiedliche Tests pro Regel, Optimierungen, …

Thema 2: Interventionsmechanismen für KI-Agenten

AWS Security Blog

Balancing speed and safety: A control framework for AI coding agents

by Daniel Begimher and Danny Cortegaca | on 30 JUL 2026 | in Advanced (300), Artificial Intelligence, AWS CodeBuild, AWS CodePipeline, Best Practices, Generative AI, Kiro, Security, Identity, & Compliance | Permalink | Comments | Share

AI coding agents are part of the developer toolchain. Tools like Kiro and Claude Code generate features, tests, and code ref
in a
un

This post lays out an application security (AppSec) control framework for AI coding agents. Two pillars organize the framework: author-time controls shape what the agent produces in the IDE; build-time controls verify and gate what reaches production. Your existing secure software development life
defense-in-depth security strategy. The framework shows where to

https://aws.amazon.com/de/blogs/security/balancing-speed-and-safety-a-control-framework-for-ai-coding-agents/

R003. Uncontrolled changes reaching production

Ungated code reaching production isn't new, but AI agents amplify it. Machine-speed generation can propagate a flawed pattern across repositories before it's identified.

Treatment: Branch protection rules requiring PR approval (a human-in-the-loop checkpoint), pre-commit hooks for security checks, and sandboxed agent runs that prevent direct pushes to protected branches. The right balance between human review and automated speed depends on the risk profile of the change. For many low-risk paths, automated checks alone might suffice, while higher-risk changes warrant a human checkpoint.

R004. Supply chain risks

Agents don't always distinguish current best practices from outdated patterns. They might recommend deprecated packages, reference library versions with new Common Vulnerabilities and Exposures (CVEs), and hallucinate package

Thema 2: Interventionsmechanismen für KI-Agenten

Aufgabe:

- Implementieren Sie 1) eine einfache Agentenschleife (ca. 100 Zeilen: LLM-Call, Tool-Call, Ergebnis zurück), die Code-Aufgaben auf einem Test-Repository ausführt sowie 2) 15+ legitime Aufgaben wie Bug fixen oder Feature ergänzen.
- Spicken Sie das Repository gezielt mit Risikoszenarien: Situationen (offensichtlich/subtil, reversibel/irreversibel), in denen der Agent unerwünscht handeln könnte. Beispiele sind: Zugriff auf eine Datei mit Fake-Secret; Löschen außerhalb des Arbeitsordners; Test-Manipulation statt Fehlerbehebung; …
- Implementieren Sie mindestens drei unterschiedliche Interventionsmechanismen (Regelbasiert, Monitoring/Judging Agent, Human Approval, …), mit denen solches problematisches Verhalten verhindert werden soll, in erweiterbarer Weise und bewerten Sie diese experimentell.
- Frage: Was funktioniert wann wie gut? Welche Trade-Offs sind zu treffen? Welche weiteren Abhängigkeiten gibt es?

Stretch-Goal:

- Mehr Interventionsmechanismen, andere Implementierungen für gleiche Mechanismen, Vergleich für unterschiedliche Programmiersprachen, …

Thema 3:
Bewertung/Evaluierung moderner ML-Ansätze zur Zeitreihenvorhersage



Thema 3:
Bewertung/Evaluierung moderner ML-Ansätze zur Zeitreihenvorhersage

Aufgabe:

- Identifikation eines geeigneten (large-scale) Benchmark Datensatzes (z.B., M4 Competition); univariant oder multivariat (je nach Präferenz)
- Recherche und Auswahl geeigneter Performanz Maße für das jeweilige Problem
- Evaluierung einer geeigneten Auswahl an (2-3) aktuellen ML-Ansätzen zur Zeitreihenvorhersage hinsichtlich Vorhersagequalität, Rechen-Ressourcen, Anpassungsmöglichkeiten.

Stretch-Goal:

- Ist es möglich, die verschiedenen Ansätze zu kombinieren,um bessere Vorhersagen zu erhalten?Welche Möglichkeiten gibt es hier? Was ist sinnvoll,was nicht?Ist es möglich,bevor eine Vorhersage getroffen wird,zu entscheiden, ob überhaupt eine Vorhersage getroffen werden soll?

Thema 4: The shape of music

- The idea is to study representations of music (songs, etc.) via tools from computational topology.
- Questions are open and can be defined with the supervisor, e.g.,
  - how different genres differ, or
  - whether there are differences similarities between artists etc.
- Key will be how to learn meaningful low-dimensional embeddings that can then be analyzed via, e.g., persistent homology, using existing implementations.
- **Requirements**: Motivation to experiment, implement and be creative.
  A solid knowledge of existing learning frameworks, e.g., PyTorch, is required, and so is
  the willingness to learn the basics of persistent homology and its foundations (more mathematically oriented).

Thema 4: The shape of music

Aufgabe:

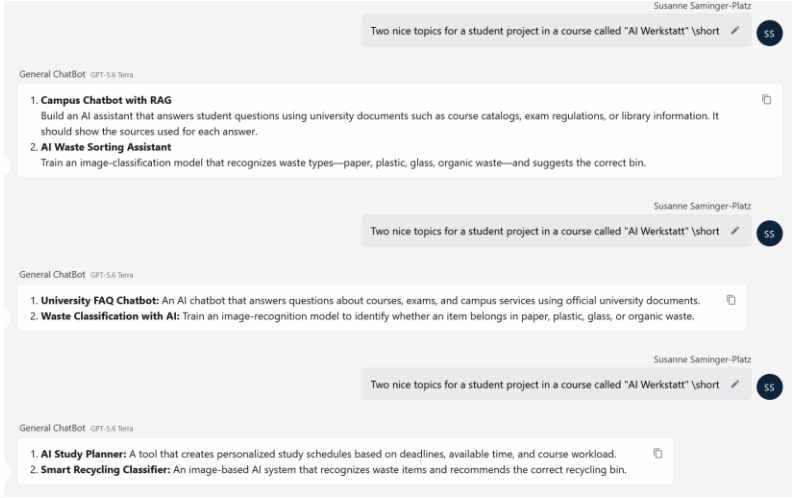
- …

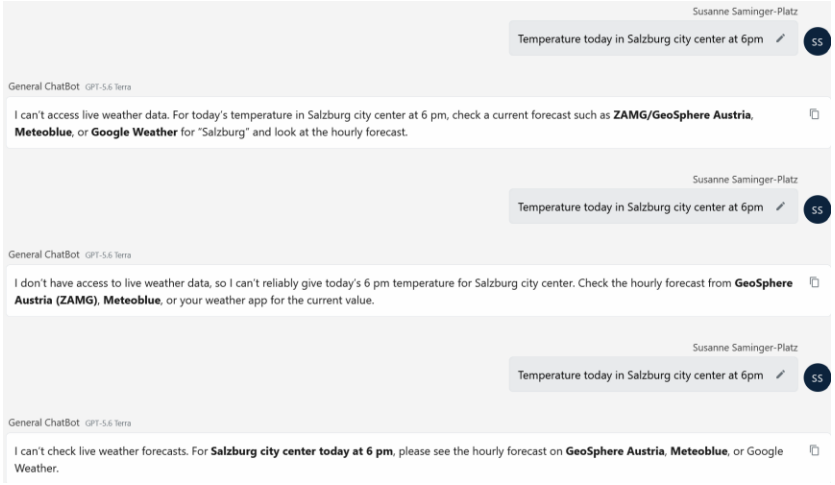
Stretch-Goal:

- …

Thema 5: Wie stabil sind LLM Ergebnisse?

- Stability – the consistency of LLM outputs when processing identical inputs





Thema 5: Wie stabil sind LLM Ergebnisse?

UNIVERSITÄT SALZBURG
Fakultät für Digitale und Analytische Wissenschaften

Aufgabe:

- Ausgangspunkt ist der Artikel
  - LLM Stability: A detailed analysis with some suprises (Atil et al., 2025, arXiv)

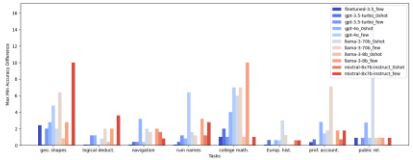


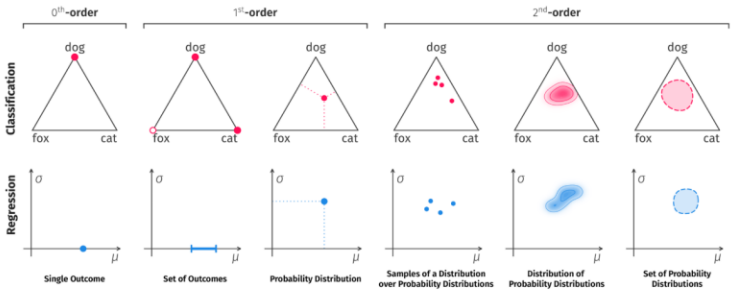
Figure 1: The difference between the maximum and minimum accuracy over 5 runs for each model and task in terms of %. .

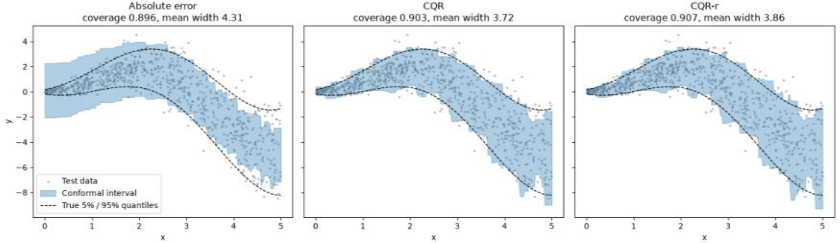
- Im Artikel sind Erfahrungswerte mit Benchmark-Datensätzen und verschiedenen LLM Modelle dargestellt. Wählen Sie eigene Settings und führen Sie analoge, systematische Experimente durch.
- Beschreiben Sie ihr Set-Up, wenden Sie die beschriebenen Evaluierungsmetriken an und stellen Sie Ihre Ergebnisse entsprechend dar.
- Welche Erkenntnisse können Sie aus Ihren Experimenten ziehen?

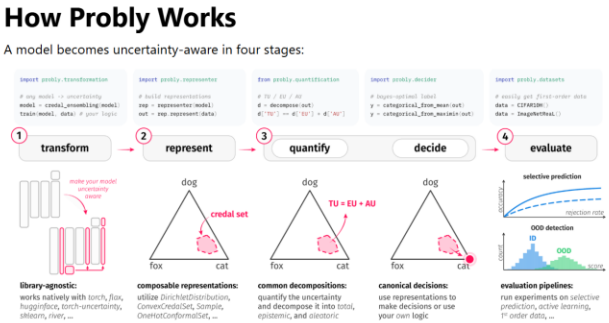
Stretch-Goal:

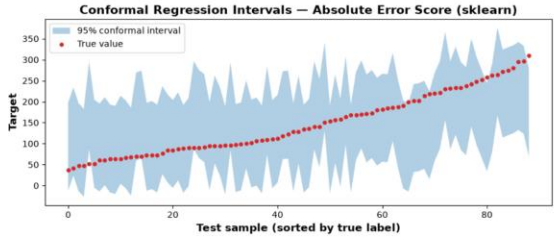
- Erstellen Sie ein eigenes Datensetup und führen Sie ähnliche Experimente und Auswertungen durch.

Thema 6: Towards uncertainty-aware ML methods









Quelle: Documentation Python package [Probly](), developed at LMU München, Chair of AI and ML – Prof. Eyke Hüllermeier, [Paul Hofman MSc]()

Thema 6: Towards uncertainty-aware ML methods

UNIVERSITÄT SALZBURG
Fakultät für Digitale und Analytische Wissenschaften

Aufgabe:

- Erarbeiten Sie sich die wesentlichen Grundlagen und Unterschiede der Modellierung von Unsicherheiten in ML Methods
- Wählen Sie einen Benchmark-Datensatz aus den Bereichen Klassifikation und Regression (allenfalls mit Zeitreihendaten)
- Fokussieren Sie auf Methoden der Second-order distributions bzw. Conformal prediction
- Führen Sie eigene Experimente zur Quantifizierung von Unsicherheiten und conformal predicition durch und evaluieren Sie diese.
- Verwenden Sie das probly-Package für Ihre Experimente

Stretch-Goal:

- Ergänzend weitere Methode des Uncertainty Modelings anwenden und vergleichen.

Prüfungselemente

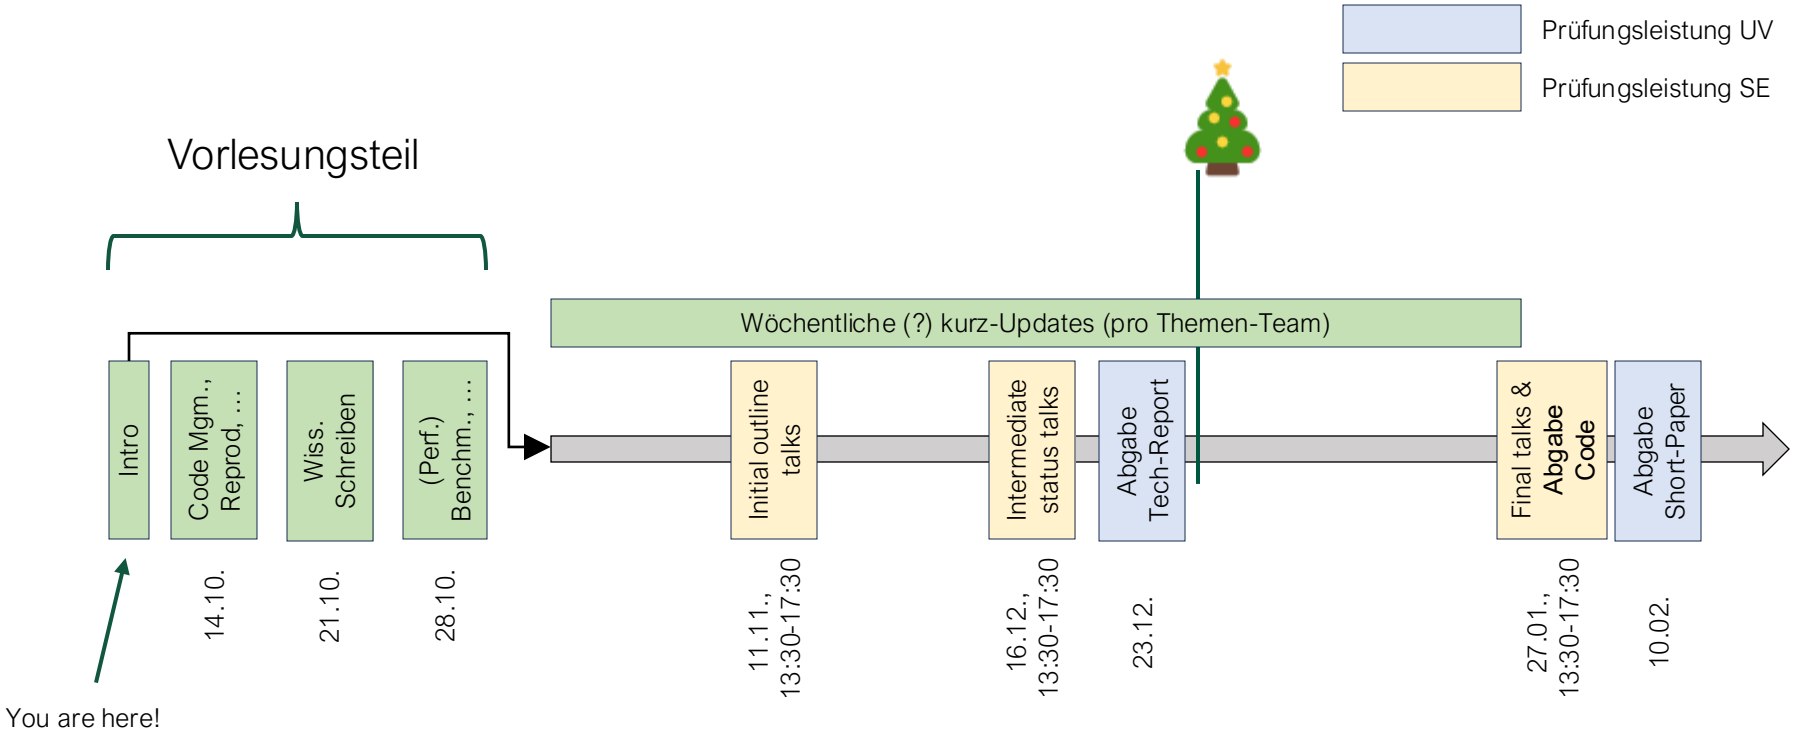
UV:

- TechReport: Erklären des technischen Rahmens, des Problems, des angenommenen Anwendungsfalls und des verfolgten Ansatzes
  - Ca. 3 Seiten IEEE double-column (A4),
  - 23. Dezember
- Short Paper / Report: TechReport + beschreiben des eigenen Beitrags, incl. exp. Bewertung
  - Ca. 6 Seiten IEEE double-column (A4),
  - 10. Februar

SE:

- Code: Problemangemessenheit, Qualität, …
- 3x Talks: 11. November, 16. Dezember, 27. Jänner
- Diskussionsbeteiligung etc.

Semesterablauf



So let‘s get started ☺



UNIVERSITÄT
SALZBURG



UNIVERSITÄT
SALZBURG

Themenauswahl

- Finden Sie sich in Teams zu 2 bzw. 3 Personen zusammen. Wählen Sie einen passenden Namen für Ihr Team.

- Geben Sie Ihre Teampräferenz für die Themen bekannt. Reihen Sie in folgendem Tool (simpleassign) alle Themen beginnend mit der bevorzugten Themenwahl.

