MACHINE LEARNING

(WS 26/27)

Mitschrift

Datum: 12.10.2026

LINEARE MODELLE

Linear Discriminant Analysis (LDA)

(Kapitel 9 im Buch)

Notation: $x \in \mathcal{X}$ → Raum unserer Input Daten (z.B. $\mathbb{R}^d$, $d > 0$) (Inputs)

$y \in \mathcal{Y}$ (Outputs) → Raum unserer Outputs (z.B. $\{0, 1\}$)

Wir werden x auch als "Features" (also Merkmale) bezeichnen.

Gegeben haben wir

$$\mathcal{D} = \{(x_n, y_n)\}_{n=1}^{N},$$

also eine Menge an (Input, Output) Tupel die wir als "Trainingsdaten" bezeichnen.

Unser Ziel wird sein eine Funktion

$$f: \mathcal{X} \to \mathcal{Y}$$

auf Basis von $\mathcal{D}$ zu "lernen".

Im Kontext von LDA nehmen wir vorerst

$$\mathcal{X} = \mathbb{R}^d \quad \text{und} \quad \mathcal{Y} = \{0, 1\}$$

an. Also, reellwertige Input-Vektoren und binäre Outputs, z.B.

$y = 0$ Klasse 0
$y = 1$ Klasse 1.

$\Rightarrow$ Klassifizierungsproblem mit 2 Klassen.

Konkret betrachten wir Modelle der Form

$$p(y = c \mid x, \theta) = \frac{p(x \mid y = c, \theta) \cdot p(y = c)}{\sum_{c'} p(x \mid y = c', \theta) \cdot p(y = c')}$$

(θ: Modellparameter; c: Label; x: Datenpunkt)

$p(y = c \mid x, \theta)$ .... A-posteriori Wahrscheinlichkeit der Klasse c (z.B. 0), gegeben Datenpunkt x und Modellparameter θ.

$p(y = c)$ ... A-priori Wahrscheinlichkeit der Klasse c

$p(x \mid y=c, \theta)$ .... klassenbedingte Wahrscheinlichkeit von x gegeben Klasse c und fixem Modellparameter θ.

Zu gegebenem Datenpunkt x und fixem θ, erhalten wir als Entscheidungsregel

$$c^* = \arg\max_c \; p(y=c \mid x, \theta) \quad (x)$$

Beispiel: $X = \mathbb{R}^d$, $y = \{0, 1\}$

Annahme 1: $p(x \mid y=c, \theta)$ lässt sich mit einer multivariaten Normalverteilung beschreiben.

$$p(x \mid y=c, \theta_c) = (2\pi)^{-\frac{d}{2}} \cdot \frac{1}{\sqrt{\det(\Sigma_c)}} \cdot e^{-\frac{1}{2}(x-\mu_c)^T \Sigma_c^{-1} (x-\mu_c)}$$

(Multivariate Normalverteilung mit Kovarianz Matrix Σ_c und Lokationsparameter μ_c)

Σ_c ... $d \times d$ Matrix

$\mu_c \in \mathbb{R}^d$

d.h. $\theta_c = \{\mu_c, \Sigma_c\}$ (Bei 2 Klassen $\theta = \{\mu_0, \Sigma_0, \mu_1, \Sigma_1\}$)

Annahme 2: $\Sigma_0 = \Sigma_1 = \Sigma$

Kovarianzmatrizen für Klasse 0 und 1 sind gleich.

Wir sehen aus (*), dass

$$p(y=c \mid x, \theta) \propto p(x \mid y=c, \theta) \cdot p(y=c)$$

↳ proportional zu

Wir setzen

$$p(y=0 \mid x, \theta) = p(y=1 \mid x, \theta)$$

um zu sehen wie die Entscheidungsgrenze aussieht.

Wir definieren

$$\pi_0 = p(y=0)$$
$$\pi_1 = p(y=1)$$

$$\pi_0 \cdot \frac{1}{(2\pi)^d \cdot \det(\Sigma_0)} \cdot \exp\left(-\frac{1}{2} \cdot (x-\mu_0)^T \Sigma_0^{-1} (x-\mu_0)\right) =$$

$$\pi_1 \cdot \frac{1}{(2\pi)^d \cdot \det(\Sigma_1)} \cdot \exp\left(-\frac{1}{2} \cdot (x-\mu_1)^T \Sigma_1^{-1} (x-\mu_1)\right)$$

Logarithmieren gibt (und da $\Sigma_1 = \Sigma_0 = \Sigma$)

$$\log(\pi_0) - \frac{1}{2} \cdot (x-\mu_0)^T \Sigma^{-1} (x-\mu_0) = \log(\pi_1) - \frac{1}{2} (x-\mu_1)^T \Sigma^{-1} (x-\mu_1)$$

$$\log(\pi_0) - \frac{1}{2} x^T \Sigma^{-1} x + \frac{1}{2} \cdot x^T \Sigma^{-1} \mu_0 + \frac{1}{2} \mu_0^T \Sigma^{-1} x - \frac{1}{2} \cdot \mu_0^T \Sigma^{-1} \mu_0 =$$
$$\log(\pi_1) - \frac{1}{2} x^T \Sigma^{-1} x + \frac{1}{2} \cdot x^T \Sigma^{-1} \mu_1 + \frac{1}{2} \mu_1^T \Sigma^{-1} x - \frac{1}{2} \mu_1^T \Sigma^{-1} \mu_1$$

$$\Leftrightarrow \quad \mu_0^T \Sigma^{-1} x - \frac{1}{2} \mu_0^T \Sigma^{-1} \mu_0 + \log(\pi_0) =$$
$$\mu_1^T \Sigma^{-1} x - \frac{1}{2} \mu_1^T \Sigma^{-1} \mu_1 + \log(\pi_1)$$

$$\Leftrightarrow \quad \left(\mu_1^T \Sigma^{-1} x - \mu_0^T \Sigma^{-1} x\right) - \frac{1}{2} \mu_1^T \Sigma^{-1} \mu_1 + \frac{1}{2} \mu_0^T \Sigma^{-1} \mu_0 + \log\left(\frac{\pi_1}{\pi_0}\right) = 0$$