MACHINE LEARNING

(WS 26/27)

Mitschrift

Datum: 12.10.2026

LINEARE MODELLE

Linear Discriminant Analysis (LDA)

(Kapitel 9 im Buch)

Notation: $x \in \mathcal{X}$ → Raum unserer Input Daten (z.B. $\mathbb{R}^d$, $d > 0$) (Inputs)

$y \in \mathcal{Y}$ (Outputs) → Raum unserer Outputs (z.B. $\{0, 1\}$)

Wir werden x auch als "Features" (also Merkmale) bezeichnen.

Gegeben haben wir

$$\mathcal{D} = \{(x_n, y_n)\}_{n=1}^{N},$$

also eine Menge an (Input, Output) Tupel die wir als "Trainingsdaten" bezeichnen.

Unser Ziel wird sein eine Funktion

$$f: \mathcal{X} \to \mathcal{Y}$$

auf Basis von $\mathcal{D}$ zu "lernen".

Im Kontext von LDA nehmen wir vorerst

$$\mathcal{X} = \mathbb{R}^d \quad \text{und} \quad \mathcal{Y} = \{0, 1\}$$

an. Also, reellwertige Input-Vektoren und binäre Outputs, z.B.

$y = 0$ Klasse 0
$y = 1$ Klasse 1.

$\Rightarrow$ Klassifizierungsproblem mit 2 Klassen.

Konkret betrachten wir Modelle der Form

$$p(y = c \mid x, \theta) = \frac{p(x \mid y = c, \theta) \cdot p(y = c)}{\sum_{c'} p(x \mid y = c', \theta) \cdot p(y = c')}$$

(θ: Modellparameter; c: Label; x: Datenpunkt)

$p(y = c \mid x, \theta)$ .... A-posteriori Wahrscheinlichkeit der Klasse c (z.B. 0), gegeben Datenpunkt x und Modellparameter θ.

$p(y = c)$ ... A-priori Wahrscheinlichkeit der Klasse c

$p(x \mid y=c, \theta)$ .... klassenbedingte Wahrscheinlichkeit von x gegeben Klasse c und fixem Modellparameter θ.

Zu gegebenem Datenpunkt x und fixem θ, erhalten wir als Entscheidungsregel

$$c^* = \arg\max_c \; p(y=c \mid x, \theta) \quad (x)$$

Beispiel: $X = \mathbb{R}^d$, $y = \{0, 1\}$

Annahme 1: $p(x \mid y=c, \theta)$ lässt sich mit einer multivariaten Normalverteilung beschreiben. (MVN)

$$p(x \mid y=c, \theta_c) = (2\pi)^{-\frac{d}{2}} \cdot \frac{1}{\sqrt{\det(\Sigma_c)}} \cdot e^{-\frac{1}{2}(x-\mu_c)^T \Sigma_c^{-1} (x-\mu_c)}$$

(Multivariate Normalverteilung mit Kovarianz Matrix Σ_c und Lokationsparameter μ_c)

Σ_c ... $d \times d$ Matrix

$\mu_c \in \mathbb{R}^d$

d.h. $\theta_c = \{\mu_c, \Sigma_c\}$ (Bei 2 Klassen $\theta = \{\mu_0, \Sigma_0, \mu_1, \Sigma_1\}$)

Annahme 2: $\Sigma_0 = \Sigma_1 = \Sigma$

Kovarianzmatrizen für Klasse 0 und 1 sind gleich.

Wir sehen aus (*), dass

$$p(y=c \mid x, \theta) \propto p(x \mid y=c, \theta) \cdot p(y=c)$$

↳ proportional zu

Wir setzen

$$p(y=0 \mid x, \theta) = p(y=1 \mid x, \theta)$$

um zu sehen wie die Entscheidungsgrenze aussieht.

Wir definieren

$$\pi_0 = p(y=0)$$
$$\pi_1 = p(y=1)$$

$$\pi_0 \cdot \frac{1}{(2\pi)^d \cdot \det(\Sigma_0)} \cdot \exp\left(-\frac{1}{2} \cdot (x-\mu_0)^T \Sigma_0^{-1} (x-\mu_0)\right) =$$

$$\pi_1 \cdot \frac{1}{(2\pi)^d \cdot \det(\Sigma_1)} \cdot \exp\left(-\frac{1}{2} \cdot (x-\mu_1)^T \Sigma_1^{-1} (x-\mu_1)\right)$$

Logarithmieren gibt (und da $\Sigma_1 = \Sigma_0 = \Sigma$)

$$\log(\pi_0) - \frac{1}{2} \cdot (x-\mu_0)^T \Sigma^{-1} (x-\mu_0) = \log(\pi_1) - \frac{1}{2} (x-\mu_1)^T \Sigma^{-1} (x-\mu_1)$$

$$\log(\pi_0) - \frac{1}{2} x^T \Sigma^{-1} x + \frac{1}{2} \cdot x^T \Sigma^{-1} \mu_0 + \frac{1}{2} \mu_0^T \Sigma^{-1} x - \frac{1}{2} \cdot \mu_0^T \Sigma^{-1} \mu_0 =$$
$$\log(\pi_1) - \frac{1}{2} x^T \Sigma^{-1} x + \frac{1}{2} \cdot x^T \Sigma^{-1} \mu_1 + \frac{1}{2} \mu_1^T \Sigma^{-1} x - \frac{1}{2} \mu_1^T \Sigma^{-1} \mu_1$$

$$\Leftrightarrow \mu_0^T \Sigma^{-1} x - \frac{1}{2} \mu_0^T \Sigma^{-1} \mu_0 + \log(\pi_0) = \mu_1^T \Sigma^{-1} x - \frac{1}{2} \mu_1^T \Sigma^{-1} \mu_1 + \log(\pi_1)$$

$$\Leftrightarrow \left(\mu_1^T \Sigma^{-1} x - \mu_0^T \Sigma^{-1} x\right) - \frac{1}{2} \mu_1^T \Sigma^{-1} \mu_1 + \frac{1}{2} \mu_0^T \Sigma^{-1} \mu_0 + \log\left(\frac{\pi_1}{\pi_0}\right) = 0$$

Datum: 14.10.2026

$$\Leftrightarrow \left(\Sigma^{-1}(\mu_1 - \mu_0)\right)^T x + \frac{1}{2} \cdot (\mu_0 - \mu_1)^T \Sigma^{-1} (\mu_0 + \mu_1) + \log\left(\frac{\pi_1}{\pi_0}\right) = 0$$

$$\Leftrightarrow \underbrace{2 \cdot \left(\Sigma^{-1}(\mu_1 - \mu_0)\right)^T x}_{\text{abhängig von } x} + \underbrace{(\mu_0 - \mu_1)^T \Sigma^{-1} (\mu_0 + \mu_1)}_{\text{Skalar}} + \underbrace{2 \cdot \log\left(\frac{\pi_1}{\pi_0}\right)}_{\text{Skalar}} = 0$$

Wir erhalten einen Ausdruck der Form

$$\boxed{a^T x + b = 0}$$ LINEARE ENTSCHEIDUNGS-GRENZE

mit

$$a = 2 \cdot \Sigma^{-1}(\mu_1 - \mu_0)$$

$$b = (\mu_0 - \mu_1)^T \Sigma^{-1} (\mu_0 + \mu_1) + 2 \log\left(\frac{\pi_1}{\pi_0}\right)$$

Betrachten wir

$$p(y=1 \mid x, \theta) = \frac{p(x \mid y=1, \theta) \cdot \overbrace{p(y=1)}^{\pi_1}}{\text{Normierung}}$$

Einsetzen der MVN + log ergibt

$$\log\left(p(y=1 \mid x, \theta)\right) = \log(\pi_1) - \frac{1}{2} \cdot (x-\mu_1)^T \Sigma^{-1} (x-\mu_1) + \underline{\text{const.}}$$

$$= \log(\pi_1) - \frac{1}{2}\left[x^T\Sigma^{-1}x - 2\cdot\mu_1^T\Sigma^{-1}x + \mu_1^T\Sigma^{-1}\mu_1\right] + \text{const.}$$

$$= \underbrace{\log(\pi_1) - \frac{1}{2}\mu_1^T\Sigma^{-1}\mu_1}_{\gamma_1} + \underbrace{\mu_1^T\Sigma^{-1}x}_{x^T\underbrace{\Sigma^{-1}\mu_1}_{\beta_1}} + \underbrace{\text{const} - \frac{1}{2}x^T\Sigma^{-1}x}_{\tau}$$

(also von der Form $\gamma_1 + x^T\beta_1 + \tau$)

τ: unabhängig von Klasse

$$\Rightarrow p(y=1 \mid x, \theta) = \frac{\exp\left(x^T\beta_1 + \gamma_1\right)}{\exp\left(x^T\beta_1 + \gamma_1\right) + \exp\left(x^T\beta_0 + \gamma_0\right)}$$

$$= \frac{1}{1 + \exp\left((\beta_0 - \beta_1)^T x + (\gamma_0 - \gamma_1)\right)}$$

Mit $\sigma(x) = \frac{1}{1+e^{-x}}$ Sigmoid



erhalten wir $$p(y=1|x,\theta) = \sigma\left((\beta_1-\beta_0)^T x + (\mu_1-\mu_0)\right)$$

Wie sieht $\mu_1-\mu_0$ aus?

$$\mu_1-\mu_0 = \log\left(\frac{\pi_1}{\pi_0}\right) - \frac{1}{2}\cdot\mu_1^T\Sigma^{-1}\mu_1 - \log\left(\frac{\pi_0}{\pi_0}\right) + \frac{1}{2}\mu_0^T\Sigma^{-1}\mu_0$$

$$= \log\left(\frac{\pi_1}{\pi_0}\right) - \frac{1}{2}\cdot(\mu_1-\mu_0)^T\Sigma^{-1}(\mu_1+\mu_0)$$

Wie sieht $\beta_1-\beta_0$ aus?

$$\beta_1-\beta_0 = \Sigma^{-1}\mu_1 - \Sigma^{-1}\mu_0 = \Sigma^{-1}(\mu_1-\mu_0) =: w$$

Ansatz: $$x_0 = \frac{1}{2}\cdot(\mu_1+\mu_0) - (\mu_1-\mu_0)\cdot\frac{\log\left(\frac{\pi_1}{\pi_0}\right)}{(\mu_1-\mu_0)^T\Sigma^{-1}(\mu_1-\mu_0)}$$

$$w^T x_0 = \frac{1}{2}(\mu_1-\mu_0)^T\Sigma^{-1}(\mu_1+\mu_0) - (\mu_1-\mu_0)^T\Sigma^{-1}(\mu_1-\mu_0)\frac{\log\left(\frac{\pi_1}{\pi_0}\right)}{(\mu_1-\mu_0)^T\Sigma^{-1}(\mu_1-\mu_0)}$$

$$= -(\mu_1-\mu_0)$$

q.t.

Wir wissen nun

$$w^T x_0 = -(\mu_1 - \mu_0)$$

$$\Rightarrow p(y=1 \mid x, \theta) = \sigma\left(\underbrace{(\beta_1 - \beta_0)}_{w}{}^T x + (\mu_1 - \mu_0)\right)$$

$$= \sigma\left(w^T x - w^T x_0\right)$$

$$\boxed{= \sigma\left(w^T (x - x_0)\right)}$$

x ↓ Datenpunkt

Beobachtung:

Ist $w^T x > w^T x_0$, dann ist $w^T(x - x_0)$ positiv und daher $\sigma\left(w^T(x-x_0)\right) > 0.5 \Rightarrow$

$$p(y=1 \mid x, \theta) > p(y=0 \mid x, \theta)$$

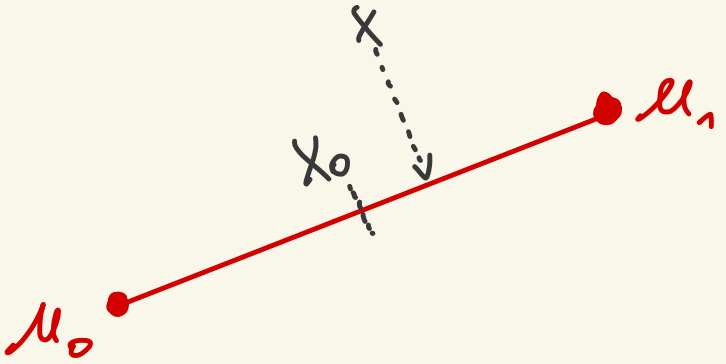
In dem Fall weisen wir x Klassenlabel 1 zu.

Geometrisch: Wenn $\Sigma_1 = \Sigma_0 = \Sigma = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$

und $\pi_1 = \pi_0$:

$$w = \mu_1 - \mu_0$$

$$x_0 = \frac{1}{2} \cdot (\mu_1 + \mu_0)$$



19.10.2026

Einschub: Maximum-Likelihood-Schätzung
(Maximum-Likelihood-Estimation (MLE))

Daten $\mathcal{D} = \{(x_1, y_1), \ldots, (x_N, y_N)\}$

$p(\mathcal{D} \mid \theta)$ ... Likelihood

Wahrscheinlichkeit der Daten $\mathcal{D}$ unter Modell mit Parameter θ

Ziel: Wir möchten θ so wählen, dass D die höchste Wahrscheinlichkeit unter unserem Modell hat (also den größten Likelihood)

$$\theta_{mle} = \arg\max_{\theta} p(D|\theta)$$

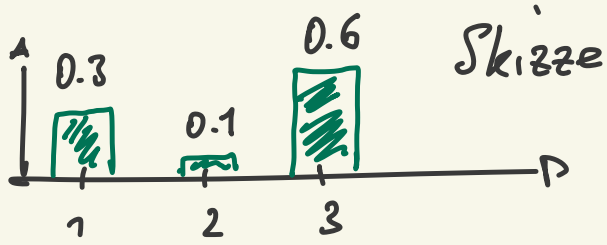
Annahme: Daten sind unabhängig und identisch verteilt (independent and identically distributed ... iid).

$$\theta_{mle} = \arg\max_{\theta} \prod_{i=1}^{N} p(y_i|x_i,\theta)$$

$$= \arg\max_{\theta} \underbrace{\sum_{i=1}^{N} \log p(y_i|x_i,\theta)}_{\text{log-likelihood}}$$

$$= \arg\min_{\theta} \underbrace{-\sum_{i=1}^{N} \log p(y_i|x_i,\theta)}_{\text{negative log-likelihood}}$$

Beispiel: Kategorielle Verteilung (Categorical Distribution CAT)



Skizze

Diskrete Wahrscheinlichkeitsverteilung (in unserem Klassifizierungsproblem mit einem Parameter pro Klasse).

$$\text{Cat}(y \mid \theta) = \prod_{c=1}^{C} \theta_c^{\mathbb{1}_{y=c}} \qquad (**)$$

C → # Klassen

$$\mathbb{1}_{y=c} = \begin{cases} 1, & \text{wenn } y = c \\ 0, & \text{sonst} \end{cases}$$

$$p(y=c \mid \theta) = \theta_c \in [0,1]$$

$$\sum_{c=1}^{C} \theta_c = 1$$

Andere Schreibweise:

Wir können $y = c$ (bei $c = 1, \dots, C$ Klassen) auch als **Binärvektor** schreiben:

$$[0, 0, 0, \dots, 0, \underbrace{1}_{\text{1 an c-ter Stelle}}, 0 \dots 0] = y$$

$$\Rightarrow \text{Cat}(y \mid \theta) = \prod_{c=1}^{C} \theta_c^{y_c}$$

Bei N Datenpunkten sieht unser **log-likelihood** folgendermaßen aus:

$$\sum_{n=1}^{N} \sum_{c=1}^{C} \mathbb{1}_{y_n = c} \cdot \log(\theta_c) \qquad \text{// von (xx)}$$

$$\Leftrightarrow \sum_{c=1}^{C} \sum_{n=1}^{N} \mathbb{1}_{y_n = c} \cdot \log(\theta_c)$$

$$\Leftrightarrow \sum_{c=1}^{C} \left(\log(\theta_c) \cdot \underbrace{\sum_{n=1}^{N} \mathbb{1}_{y_n = c}}_{N_c := \text{Anzahl an } y \text{ mit } y = c} \right)$$

$$\Longleftrightarrow \sum_{c=1}^{C} N_c \cdot \log(\theta_c)$$

negative log-likelihood

Wir versuchen $-\sum_{c=1}^{C} N_c \cdot \log(\theta_c)$ zu minimieren

(bzgl. $\theta_1, \dots \theta_C$) unter der Nebenbedingung

$$\sum_{c=1}^{C} \theta_c = 1$$

Ansatz mittels Lagrange Multiplizierer:

$$L(\theta, \lambda) = -\sum_{c=1}^{C} N_c \cdot \log(\theta_c) - \lambda \cdot \left(\sum_{c=1}^{C} \theta_c - 1 \right)$$

↳ Lagrange Multiplizierer

$$\frac{\partial L}{\partial \lambda} = -\left(1 - \sum_{c=1}^{C} \theta_c\right) = 0 \Rightarrow \sum_{c=1}^{C} \theta_c = 1$$

$$\frac{\partial L}{\partial \theta_c} = -\frac{N_c}{\theta_c} + \lambda = 0 \quad \text{(für } \theta_1, \dots \theta_C\text{)}$$

$$\Rightarrow \lambda = \frac{N_c}{\theta_c} \Rightarrow \lambda \theta_c = N_c$$

Wir wissen auch $\sum_c N_c = N$

Summieren über $c = 1, \dots, C$

$$\sum_{c=1}^{C} \lambda \theta_c = \underbrace{\sum_{c=1}^{C} N_c}_{N}$$

$$\Leftrightarrow \lambda \cdot \underbrace{\sum_{c=1}^{C} \theta_c}_{1} = N \quad \Rightarrow \boxed{\lambda = N}$$

Einsetzen von $\lambda = N$ in $\lambda \theta_c = N_c$, ergibt

$$\boxed{\theta_c = \frac{N_c}{N}}$$

Max. Likelihood Schätzer

Weiter mit LDA: Für einen Datensatz $D = \{(x_1, y_1), \dots, (x_N, y_N)\}$ wollen wir den Likelihood unter unserem Modell anschreiben. Für $p(x \mid y=c, \theta)$ hatten wir bereits die multivariate Normalverteilung (MVN) mit Parametern (μ_c, Σ_c). Für $p(y=c)$ nehmen wir $\mathrm{Cat}(y \mid \pi)$.

↳ Parameter der kat. Verteilung

$$p(\mathcal{D} \mid \{\theta, \pi\}) = \prod_{n=1}^{N} \mathrm{Cat}(y_n \mid \pi) \cdot \prod_{c=1}^{C} \mathrm{MVN}(x_n \mid \mu_c, \Sigma_c)^{\mathbb{1}_{y_n=c}}$$

Anm.: $\theta = \{\mu_1, \Sigma_1, \ldots \mu_C, \Sigma_C\}$

Loganitlimieren:

$$\underbrace{\log p(\mathcal{D} \mid \{\theta, \pi\})}_{\text{log-Likelihood}} = \sum_{n=1}^{N} \sum_{c=1}^{C} \mathbb{1}_{y_n=c} \cdot \log(\pi_c) + \log\left(\prod_{n=1}^{N} \prod_{c=1}^{C} \mathrm{MVN}(x_n \mid \mu_c, \Sigma_c)^{\mathbb{1}_{y_n=c}} \right)$$

$$= \sum_{n=1}^{N} \sum_{c=1}^{C} \mathbb{1}_{y_n=c} \cdot \log(\pi_c) + \sum_{c=1}^{C} \sum_{n: y_n=c} \log\left(\mathrm{MVN}(x_n \mid \mu_c, \Sigma_c)\right)$$

Beobachtung: beide Terme und können separat maximiert werden.

Für $\sum_{n=1}^{N} \sum_{c=1}^{C} \mathbb{1}_{y_n = c} \log(\pi_c)$ kennen wir schon

$$\boxed{\pi_c = \frac{N_c}{N}}$$

von vorher

Für $\sum_{c=1}^{C} \sum_{n: y_n = c} \log\left(MVN(x_n \mid \mu_c, \Sigma_c)\right)$

$\underbrace{\qquad\qquad\qquad\qquad}$ log-Likelihood der MVN für Klasse c.

erhalten wir (ohne Herleitung):

$$\boxed{\mu_c = \frac{1}{N_c} \cdot \sum_{n: y_n = c} x_n}$$

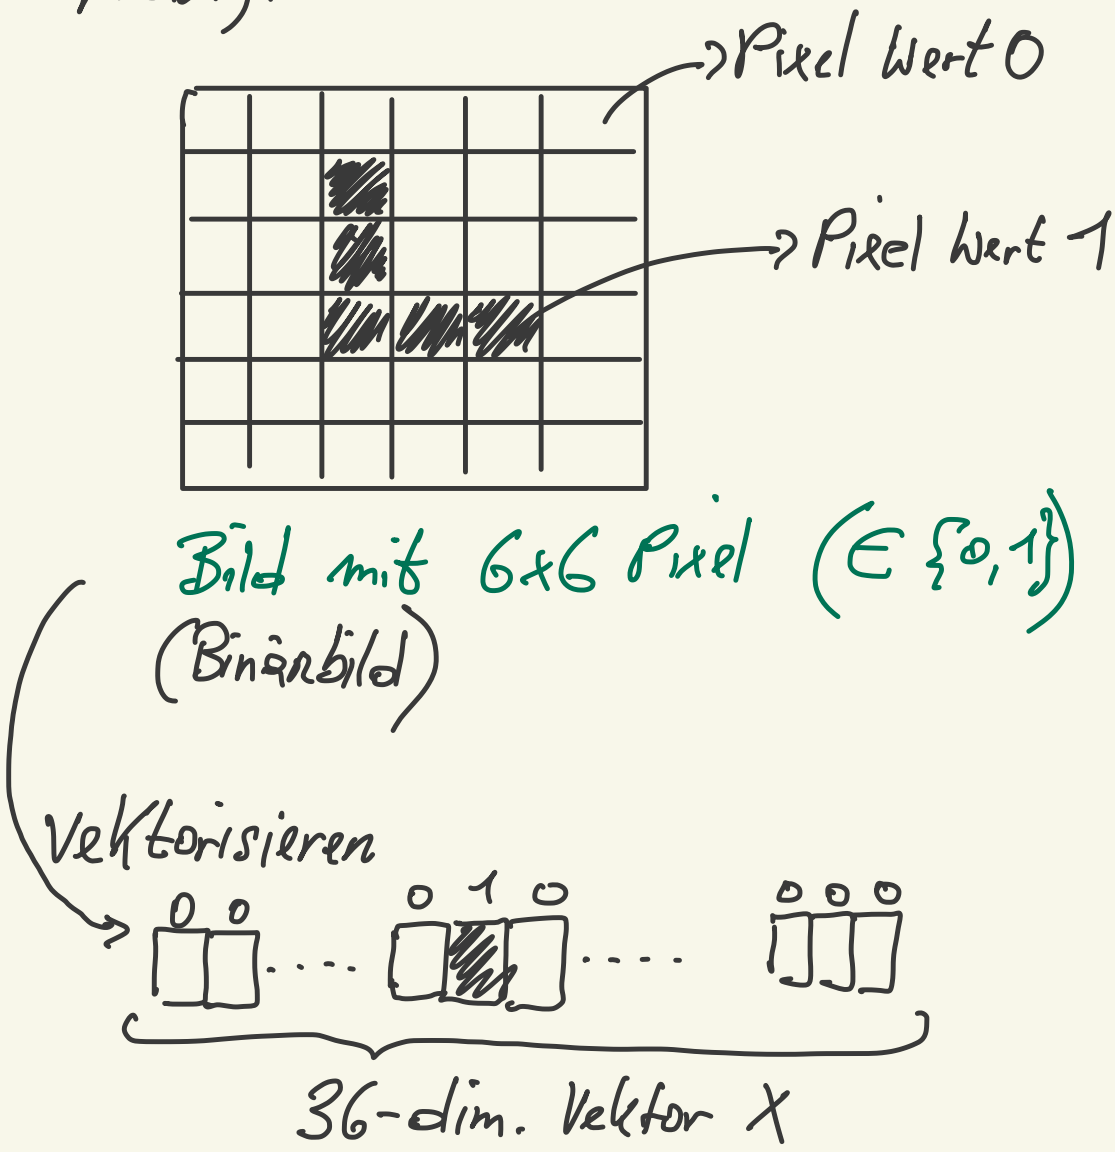
$$\boxed{\Sigma_c = \frac{1}{N_c} \cdot \sum_{n: y_n = c} (x_n - \mu_c) \cdot (x_n - \mu_c)^T}$$

Für LDA mit Annahme $\Sigma_1 = \Sigma_2$ (im 2-Klassen Fall)

$$\Sigma = \frac{1}{2} \cdot (\Sigma_1 + \Sigma_2)$$

,

Beispiel (zu Normalverteilung als nicht passendes Modell).



Wir könnten in diesem Fall, jede einzelne der 36 Dimensionen (von x) als Bernoulli-verteilt modellieren, d.h.

$$\mathrm{Ber}(y|\theta)$$